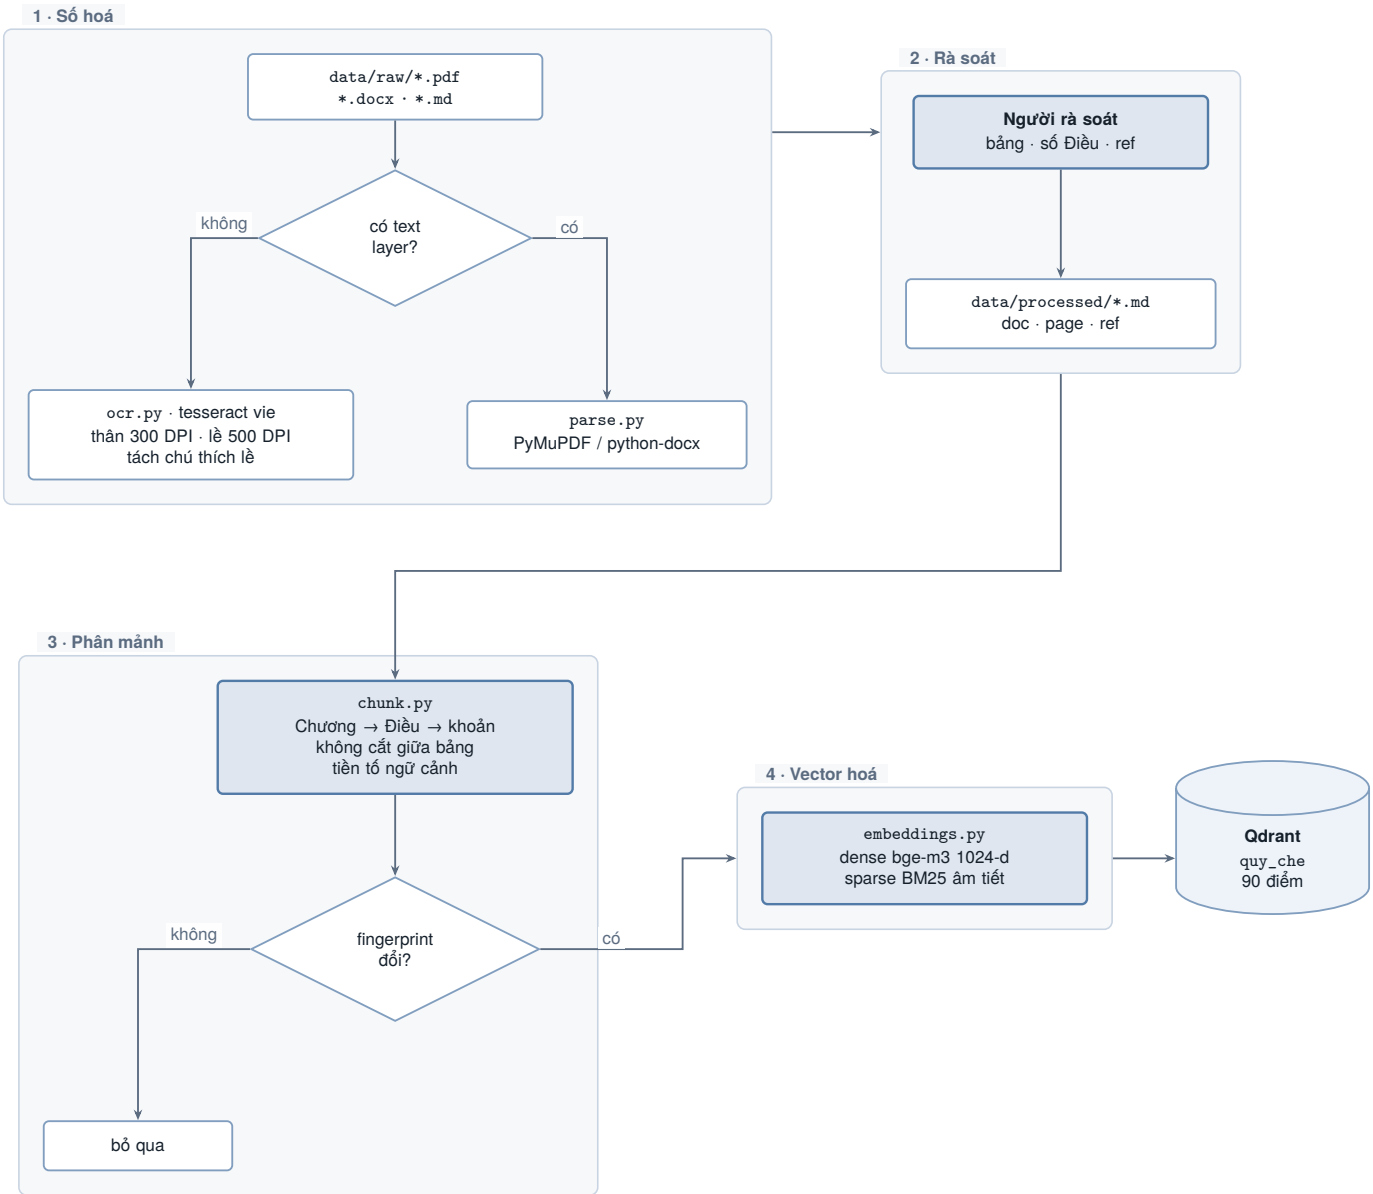
1 · Số hoá
data/raw/*.pdf
*.docx · *.md
có text layer?
không
có
ocr.py · tesseract vie
thân 300 DPI · lề 500 DPI
tách chú thích lề
parse.py
PyMuPDF / python-docx
2 · Rà soát
Người rà soát
bảng · số Điều · ref
data/processed/*.md
doc · page · ref
3 · Phân mảnh
chunk.py
Chương → Điều → khoản
không cắt giữa bảng
tiền tố ngữ cảnh
fingerprint đổi?
không
có
bỏ qua
4 · Vector hoá
embeddings.py
dense bge-m3 1024-d
sparse BM25 âm tiết
Qdrant
quy_che
90 điểm