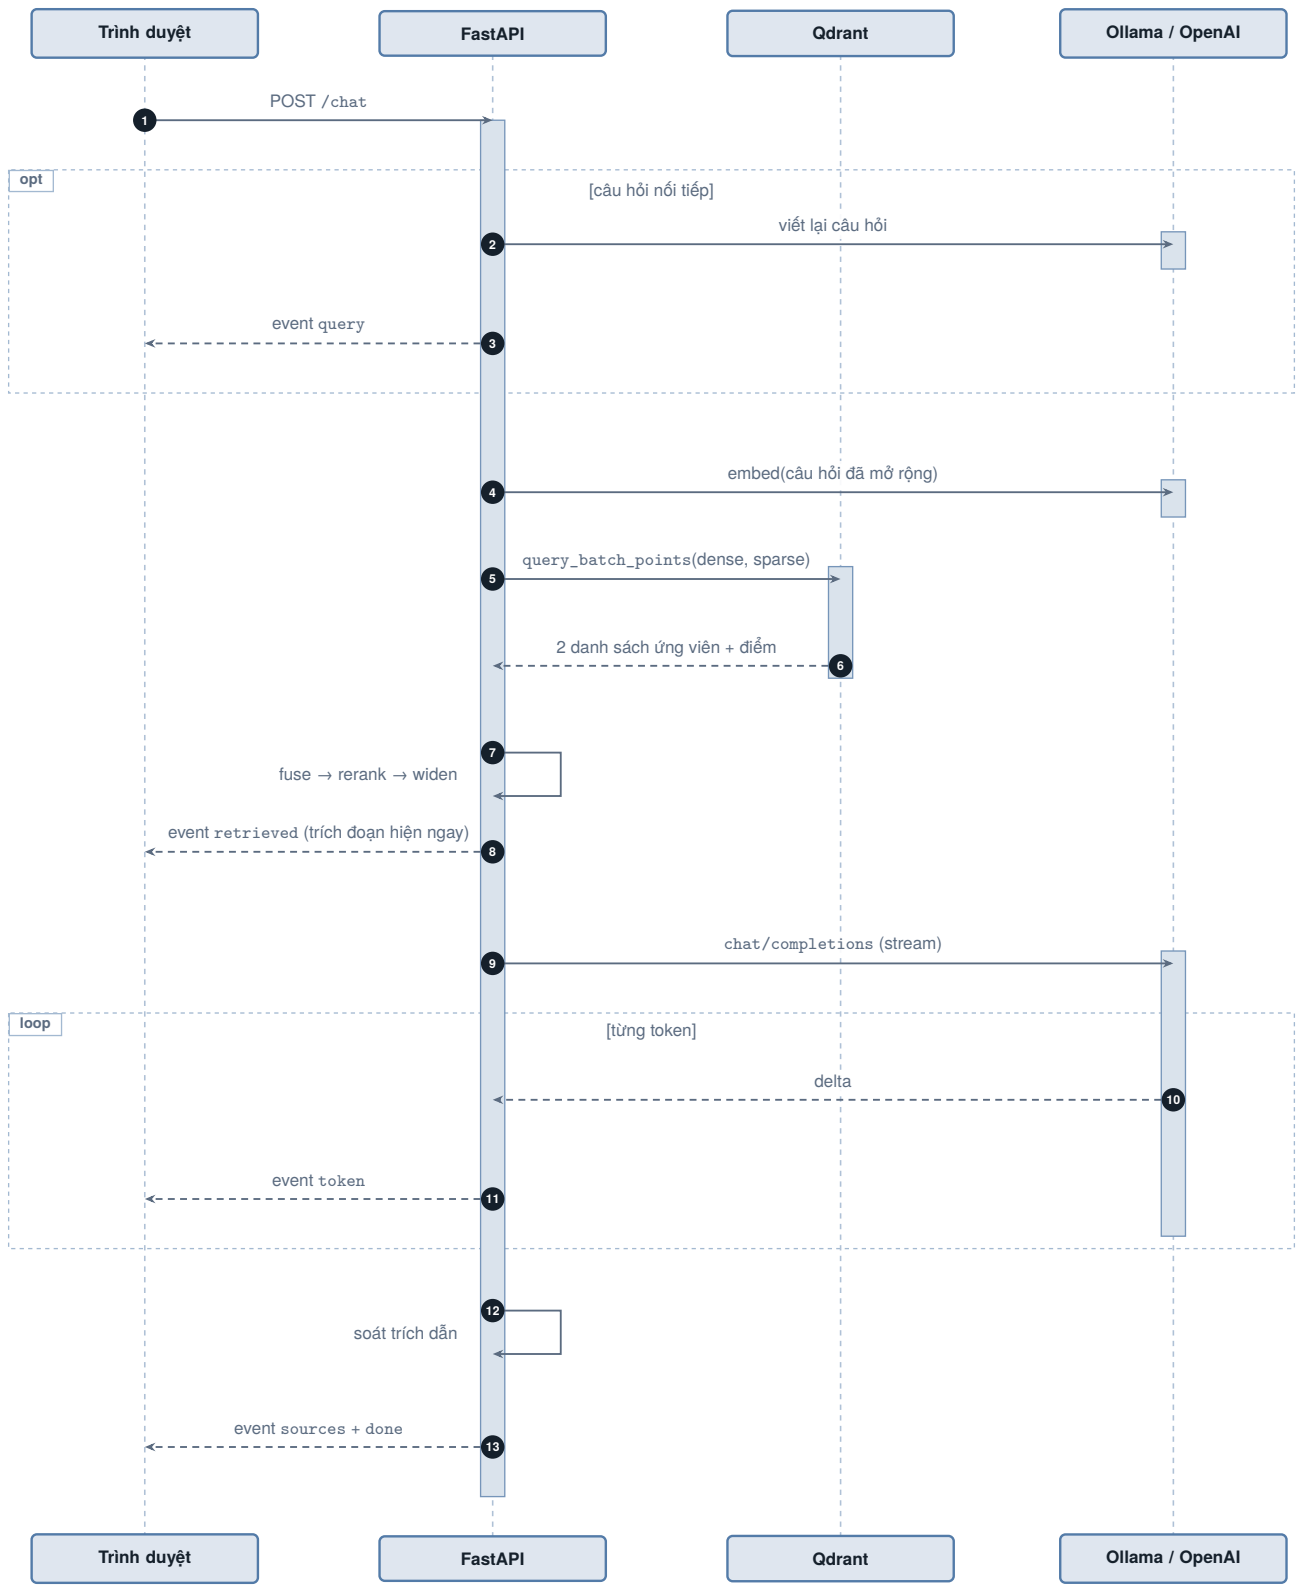
Trình duyệt
FastAPI
Qdrant
Ollama / OpenAI
POST /chat
1
opt
[câu hỏi nối tiếp]
viết lại câu hỏi
2
event query
3
embed(câu hỏi đã mở rộng)
4
query_batch_points(dense, sparse)
5
2 danh sách ứng viên + điểm
6
7
fuse → rerank → widen
event retrieved (trích đoạn hiện ngay)
8
chat/completions (stream)
9
loop
[từng token]
delta
10
event token
11
12
soát trích dẫn
event sources + done
13
Trình duyệt
FastAPI
Qdrant
Ollama / OpenAI